Devolutiva da Parte 1 — Trabalho de Agentes de IA

- **Turma**: BCC
- **Grupo**: 3
- **Integrantes**: Emily Oliveira Gomes; Felipe Macena Silveira; Matheus Rodrigues de Jesus
- **Repositório**: https://github.com/MatheusRodri/bot-agendeakiai
- **Tema do case**: AgendeAkiAI: recomendação e agendamento de serviços de beleza por ocasião.
- **Nota final: 7,4**

1. Avaliação por critério

A nota de cada critério é a soma dos subcritérios (atendido = pontos cheios; parcial = metade; não atendido = zero), com duas casas decimais. Só o subtotal e a nota final são arredondados a uma casa.

Critério	Peso	Nota	Justificativa
A qualidade da escolha do tema	1,8	1,19	Falta o tempo de como o problema se resolve hoje. O verificador existe, mas cobre só a segurança das ferramentas (escrita, erro) e não a qualidade da recomendação, e o critério de sucesso (4 de 4 cenários fixos) não mede se a tarefa foi bem feita.
Usuários e interação	1,5	1,50	Completo: perfis, interação, diálogo de exemplo e casos de complexidade estão bem definidos.
O workflow	1,3	1,30	Completo: os passos, quem decide em cada um e a confirmação da escrita estão marcados.
Análise dos modelos	1,1	0,20	A análise ficou reduzida a um único modelo (Mistral Small): não compara três candidatos, não traz a conta de custo com números nem casos rodados. A decisão com condição de mudança está presente.
O agente rodando	3,0	2,10	Agente, laço, orçamento e ferramenta externa funcionam, mas os quatro logs foram gerados por um modelo simulado que decide por palavras-chave, e não pelo LLM escolhido, então não demonstram os casos.
A justificativa da arquitetura	0,7	0,50	Falta o diagrama da arquitetura (entrada, etapas, ferramentas e condições de parada); a descrição do sistema e a tabela de ferramentas estão boas.
O rigor do prompt	0,6	0,60	Completo: prompts versionados e comentário de técnica, contrato e o que a etapa impede.
Subtotal	**10,0**	**7,39**	Soma dos sete critérios
Nota Final		**7,4**	Subtotal 7,39 arredondado a uma casa decimal

2. Verificação dos requisitos

Status de cada subcritério da rubrica, com a evidência encontrada no repositório do grupo (arquivo e linha).

Sub	Requisito	Status	Evidência
1a	Problema em uma frase; quem sofre nomeado concretamente	Atendido	docs/case.md:5 — frase única (“o cliente que procura um serviço de beleza para uma ocasião precisa combinar manualmente ocasião, estilo, orçamento, localização e disponibilidade…”); docs/case.md:7 — “cliente final que precisa se preparar para um evento”. Perfil de usuário final, no limite do concreto, mas não é “os usuários” genérico

Sub	Requisito	Status	Evidência
1b	Contexto nos cinco itens do §2.1	Parcial	Onde roda e quem aciona: docs/case.md:7 (chat da área do cliente, acionado pelo cliente). Antes/depois: docs/case.md:9. Regras do domínio: docs/case.md:11 (orçamento, bairro, pedido atual > histórico, cancelamento 48 h). **Falta o tempo** de como se resolve hoje (case.md:9 descreve a navegação por filtros, sem duração). "O que dá errado hoje" (case.md:13) lista os cenários de teste do sistema, não falhas observadas no processo atual
1c	Verificador que existe, aplicável por outra pessoa	Parcial	docs/case.md:76, src/verificar.py:37-67, dados/casos-avaliacao.json:1-35 — teste automatizado sobre 4 cenários rotulados, aplicável. Mas verifica apenas escrita/erro/trecho de resposta (segurança das ferramentas), não a qualidade da recomendação, que é o valor do sistema; e os 4 logs que ele confere foram produzidos pelo modelo mock determinístico. Começo de verificador existe, cobertura do problema central não
1d	Critério de sucesso com número e denominador; assimetria	Parcial	docs/case.md:78 — "4 de 4 cenários" e "0 de 3 cenários sem confirmação pode registrar agendamento" (duas métricas, a segunda cobre o erro grave). O denominador (4 cenários fixos, rodados por regra determinística) não mede o sucesso da tarefa (recomendar bem); a assimetria do custo do erro não é declarada como tal
1e	Dados com origem e três casos; dado sensível; maior risco com plano B	Atendido	Origem simulada e os três casos nomeados (divergência moderno×clássico, cliente-inexistente, consulta sem reserva): docs/case.md:82. Dado sensível declarado e simulado: docs/case.md:84. Maior risco concreto (catálogo/agenda real inconsistente entre busca e confirmação) com plano B (revalidar na escrita): docs/case.md:95
2a	Tabela de perfis com o que **podem** fazer; quem aprova irreversível; usuário principal	Atendido	docs/case.md:17-21 (três perfis, quatro colunas); usuário principal: case.md:19; quem confirma a escrita irreversível: cliente final (case.md:47)
2b	Interação: canal e porquê; quem começa; trocas; o que devolve e formato; como termina	Atendido	docs/case.md:23 (chat web, porque o cliente não conhece os filtros; cliente inicia; 2 a 4 trocas; texto curto com opções estruturadas) e docs/case.md:25 (término sem escrita e chamada à Operação quando não resolve)
2c	Diálogo de exemplo do início ao fim	Atendido	docs/case.md:29-35 (pedido → opção → confirmação → agendamento confirmado); outro em README.md:74-80
2d	Complexidade: o que não informa; contradição; quando sabe o suficiente; quando chama humano e qual perfil	Atendido	docs/case.md:37 (filtro que falta, histórico "moderno" × pedido "clássico", suficiência) e docs/case.md:25 (chama a Operação AgendeAki)
3a	Fluxo de 5 a 8 passos	Atendido	docs/case.md:41-48 — 8 passos, do pedido ao retorno/escalonamento
3b	Cada passo marcado com quem decide	Atendido	docs/case.md:41-48 — dois [decide: MODELO] (2 e 5), demais [decide: CÓDIGO]
3c	Escrita marcada com reversibilidade; irreversível com confirmação pelo perfil	Atendido	docs/case.md:47 — "[ESCRITA — irreversível nesta POC; confirma: cliente final]"; no código, bloqueio em src/main.py:366-371

Sub	Requisito	Status	Evidência
5a	Três candidatos comparados nos eixos do caso	Não atendido	docs/modelos.md:5,11-18 — um único modelo (Mistral Small); a tabela de eixos justifica só ele. Uma versão anterior com três candidatos (Mistral Small, GPT-4o-mini, Gemini 1.5 Flash) foi removida no commit 5852115 ("docs: restrict model choice to Mistral", 20/09)
5b	Conta de custo tokens × chamadas × preço; por execução, 100 execuções, semestre	Não atendido	docs/modelos.md:22-30 — só a fórmula, sem números. Os preços aparecem apenas no código (src/main.py:426-428: US$ 0,15/0,60 por milhão). A conta numérica existia na versão removida em 5852115
5c	Cinco casos rodados nos três candidatos, em tabela, com evidência	Não atendido	docs/modelos.md:34-42 — os cinco casos estão listados, mas o próprio documento diz que a avaliação real "será registrada quando a equipe decidir consumir a franquia"; nenhuma saída, script ou log de comparação
5d	A decisão e a condição de mudar de ideia	Atendido	Decisão: docs/modelos.md:5; condição: docs/modelos.md:46 (falhar em chamar a ferramenta correta, desrespeitar a confirmação, exceder custo/latência). Decisão sem comparação que a sustente
6a	Python + openai, base_url e chave por ambiente; 2 a 4 ferramentas; escrita com confirmação	Atendido	src/main.py:15-16,121-130,421-425 (cliente OpenAI com LLM_BASE_URL/OPENAI_API_KEY); 3 ferramentas: src/main.py:32-71; escrita confirmar_agendamento bloqueada sem confirmação: src/main.py:365-383. Ressalva: a confirmação é a flag de linha de comando –confirmar (main.py:464), dada **antes** de o cliente ver a opção escolhida — não há pausa para o humano aprovar a opção concreta
6b	Estado explícito, orçamento, motivo de término, log da trajetória, erro como dado	Atendido	Estado AgentState: src/main.py:83-97; orçamento de passos/tokens/custo: main.py:74-80,400-407; motivo de término: main.py:278-312,344-352,409-412; trajetória com ferramenta, argumentos, resultado e erro: main.py:329-339; erro como dado com como_continuar: src/tools.py:46-75, main.py:366-390; falha do provedor registrada: main.py:285-290
6c	Ferramenta atravessa a fronteira do processo	Atendido	API HTTP mock em processo separado (src/mock_api.py, iniciada por src/demo.py:73-80 ou python -m src.mock_api); camada HTTP com tratamento de erro de rede, HTTP e JSON: src/tools.py:22-67
6d	Os quatro casos do §4.5 executados, com log em logs/	Não atendido	logs/01-caso-simples.json (escrita confirmada agd-001), logs/02-divergencia.json, logs/03-registro-inexistente.json (erro CLIENTE_NAO_ENCONTRADO contornado), logs/04-sem-acao-principal.json (sem chamada de escrita). **Todos com "modelo": "mock-agendeakiai-v1"** — o MockDecisionModel (src/main.py:164-255) decide por palavras-chave e monta a resposta por template; nenhum log mostra o Mistral decidindo. Os casos rodaram, mas não demonstram "que o modelo escolhido dá conta" (§4). Divergência resolvida por regra fixa (main.py:254: se o texto contém "classico", prefixa a frase de priorização)
8a	Sistema em 3 a 5 linhas; nível de autonomia e por que não o de baixo; tabela de ferramentas com 5 colunas	Atendido	docs/case.md:52 (sistema), docs/case.md:54 ("agente limitado" e por que não roteador/formulário), docs/case.md:56-60 (tabela com as cinco colunas, incluindo "API HTTP mock do AgendeAki")

Sub	Requisito	Status	Evidência
8b	Diagrama da arquitetura; parágrafo sobre a decisão que justifica agente	Parcial	**Não há diagrama de arquitetura** (entrada, etapas, onde modelo/código decidem, ferramentas, condições de parada). docs/arquitetura-v1.md existiu e foi removido no commit 0f173ca (20/09). Há apenas a lista do fluxo (README.md:195-201) e o workflow (case.md:41-48), sem condições de parada. O parágrafo da decisão está em docs/case.md:54,64
9a	Prompts em prompts/, versionados, com prompt × modelo × parâmetros	Atendido	prompts/agente-v1.txt:1-8 (id, versão, técnica, modelo mistral-small-2603, temperature=0.2, max_tokens=600, contrato, o que impede); carregado do arquivo em src/main.py:28,263; versionado no git
9b	Comentário no código: técnica e porquê, contrato e proibido, o que impede	Atendido	src/main.py:133-137 — única etapa que chama o modelo: zero-shot e por quê; contrato (ferramenta ou até 5 frases); proíbe inventar disponibilidade e escrever sem confirmação; impede alucinação de catálogo e agendamento autônomo

3. Execução

4. Observações técnicas

- Os quatro logs de logs/ (commit 3c3faad) têm "modelo": "mock-agendeakiai-v1", custo_usd 0.0 e contagens de tokens fixas (src/main.py:196,200). O adaptador real (OpenAIChatModel, src/main.py:121-161) nunca aparece em um log. Para a Parte 2, gere os logs com o LLM real (o Mistral declarado).
- O verificador depende da redação do modelo simulado e do código de erro da ferramenta de histórico. Verifique propriedades do comportamento (por exemplo, "não houve escrita sem confirmação", "o histórico foi consultado") em vez de trechos exatos de texto; e considere forçar, por código, a consulta ao histórico antes da recomendação.
- Falta um conjunto rotulado de pedidos com a recomendação esperada: nada hoje confere se a recomendação é adequada à ocasião, que é o valor do produto. A linha de base também não foi medida (docs/medicao-baseline.md).
- A análise de modelos foi reduzida a um único modelo, sem os cinco casos rodados; a versão com três candidatos e a conta de custo foram removidas em 20/09 (commit 5852115), assim como o diagrama de arquitetura (docs/arquitetura-v1.md, commit 0f173ca). Restaure-os na Parte 2.
- A confirmação do agendamento é a flag –confirmar (src/main.py:464), dada antes de o cliente ver a opção escolhida; não há pausa para o humano aprovar a opção concreta. O README (linha 175) afirma que também a mensagem precisa conter o pedido, o que o código não verifica (src/main.py:366).
- O .env.example traz valores não secretos (LLM_BASE_URL e LLM_MODELO); deixe só os nomes das variáveis.
- A pasta instructions/ contém cópias do enunciado e da visão geral da disciplina; não é material do grupo e pode sair do repositório.
- Strings quebradas em literais adjacentes em src/main.py:176-177 e 248-249: mantenha cada texto em um literal só.